

프로젝트 코드 분석 · 발표자료

NewsSignal AI

네이버 뉴스 기반 주식 호재·악재 분석 대시보드

JDK 8

Servlet · JSP

MariaDB

Tomcat WAR

LLM · Groq

도구·기법 선택 이유 · 단계별 구현 원리 · 문제와 수정 · 향후 개선

AGENDA

목차

01

프로젝트 개요

무엇을, 왜, 어떤 제약으로

02

시스템 아키텍처

계층·패키지·외부 연동

03

핵심 파이프라인

수집 → 그룹화 → 분석 → 표출

04

단계별 구현 상세

수집 · 분석/요약 · 표출 · 인프라

05

도구 선택 이유

왜 썼나 · 장단점

06

핵심 기법 개념

무슨 개념이고 왜 썼나

07

초기 구현 & 변천

처음 방식과 그만둔 것

08

문제와 해결 (5)

데이터·시세·구조·LLM·섹터

09

현재 구현 방식

지금은 이렇게 동작한다

10

향후 개선 제안

다음에 무엇을 할까

프로젝트 개요

목적

- 네이버 뉴스를 수집·AI 분석해 종목/섹터별 호재·악재 신호를 시각화
- 유사 뉴스를 그룹화해 대표 1건만 LLM 분석 → 비용 절감이 설계의 핵심
- KIS 실시간 시세·DART 재무와 연동

기술 제약 (고정)

- JDK 8 · 순수 Servlet 3.0 + JSP + MariaDB + Tomcat WAR
- Spring Boot / React / FastAPI 도입 금지
- 라이브러리도 JDK8 호환 버전 상한 유지

외부 연동

● 네이버 뉴스 API

기사 수집 (키워드 검색)

● KIS OpenAPI

실시간 시세·차트

● DART OpenAPI

기업 재무·개황

● LLM

Groq / Gemini / Ollama

시스템 아키텍처



표출 (user)

DashboardServlet · StockInfoServlet · JSP/JS 대시보드



분석 (analyzer)

SimilarityService · AnalyzeService · StockResolver · GroupSummaryService



수집 (collector)

NaverNewsApiCollector · QuotaGuard · Scheduler · CollectJob · AnalyzeJob



공통 (common) · 저장소

Db(HikariCP) · CsrfFilter · KisApiClient | MariaDB (utf8mb4)

같은 Tomcat·DB를 형제 프로젝트와 공유 → 컨텍스트를 /newssignal2 로 분리

핵심 파이프라인

1

수집

네이버 API · 키워드 기반
DB 적재 (제목/요약/링크)

2

그룹화

content_hash 중복제거
Jaccard 유사도 그룹화

3

AI 분석

대표 1건만 LLM 호출
호재/악재·영향도·섹터·종목

4

매핑·전파

StockResolver 종목 매칭
그룹 전체에 결과 전파

5

표출

DashboardServlet 집계
최근 3일 대시보드

💡 **설계상 절대 원칙** 유사 그룹화 → 대표 1건만 분석 → 그룹 전파. 뉴스 건건이 분석하면 LLM 비용이 폭증한다.

수집 (Collect)

관련 시스템 · 클래스

- NaverNewsApiCollector — 네이버 검색 API → DTO
- CollectJob — 수집 1회 실행(적재까지만)
- QuotaGuard — 일일 25,000 한도·동적 주기
- NewsCollectScheduler — 데몬 주기 실행기
- ArticleService — 저장·중복제거·그룹화
- SimilarityService — content_hash·Jaccard

동작 원리

1. 키워드 선정: 증시·경제·정책·과학 + 상장 종목 전체 (1회 100개씩 회전)
2. 한도 체크(QuotaGuard) → 네이버 API 호출(키워드당 30건)
3. content_hash로 완전중복 제거 (중복은 그룹 카운트만 +1)
4. 최근 24h 활성 그룹과 Jaccard 매칭 → 합류·대표교체 또는 신규 그룹
5. 그룹·섹터 매핑 + 요약 갱신, 다음 회전 인덱스 저장

기법 · 도구 content_hash 중복제거 · Jaccard 유사 그룹화 · 데몬 스케줄러(누수 방지) · 동적 주기 | 현재: 자동 10분

분석 · 요약 (Analyze)

관련 시스템 · 클래스

- AnalyzeJob — 분석 1회 실행(중복 가드)
- AnalyzeService — 대상 조회·배치 호출·저장
- callGroqBatch / Ollama / Gemini — 제공자별 LLM
- parseBatchResults — 견고 파싱 + 점수 clamp
- StockResolver — 종목명·코드 매칭(2,700+)
- GroupSummaryService — 규칙기반 요약(보조)

동작 원리

1. 대상: 미분석 + duplicate_count≥2 + 최근 2일, 노출도·최신 순 상위 200
2. 제공자 선택(groq/ollama/gemini) → 그룹 N개를 JSON 배치로 호출
3. JSON 강제 프롬프트(한국어·허용 섹터·스키마) → 파싱·점수 clamp
4. 저장: 호재/악재·영향도·요약 + 그룹 전파(analyzed_yn='Y')
5. 섹터·종목·거시 매핑(이름매칭+화이트리스트) / 429 한도 처리

기법 · 도구 대표 1건+전파 · 배치 호출 · 노출도 컷 · 제공자 추상화 · JSON 강제 | 현재: '분석·요약 실행' 버튼(Groq)

표출 (Display)

관련 시스템 · 클래스

- DashboardServlet — /api/dashboard 집계
- StockInfoServlet — /api/stock/info 시세·재무
- KisApiClient — 시세 캐시·throttle·토큰영속화
- dashboard.jsp / dashboard.js — 화면·비동기
- CollectRunServlet / StatusServlet — 버튼·폴링

동작 원리

1. 집계 쿼리(PreparedStatement): 주요 이슈·섹터·종목·거시 신호
2. 공통 필터: analyzed_yn='Y' AND 최근 3일
3. 섹터/종목 숫자 = $\sum$ duplicate_count (버즈랑 가중)
4. 실시간 시세: KIS 12초 캐시 + 실패 시 마지막 정상값(0 깜빡임 방지)
5. 버튼: CSRF POST → AnalyzeJob → 상태 폴링 → 화면 갱신

인프라 (Infra)

관련 시스템 · 클래스

- Tomcat 8.5 WAR — 컨텍스트 /newssignal2
- MariaDB 10.1 + HikariCP 풀
- Groq(기본) / Ollama(선택) / Gemini(선택)
- env/ 번들 — JDK·Tomcat·Maven·MariaDB
- Git / GitHub — 코드·문서·SQL

동작 원리

1. start.ps1: 키 설정 → MariaDB 자동기동 → (Ollama) → 빌드
2. WAR을 webapps/newssignal2.war 로 핫 배포 → catalina run
3. MariaDB 먼저 안 뜨면 HikariCP 실패=404 → 자동기동으로 방지
4. 형제 /newssignal과 Tomcat·DB·KIS계정 공유 → 비활성 권장
5. 키는 환경변수, start.ps1·env/는 .gitignore

기법 · 도구 원클릭 기동 · 토큰 디스크 영속화 · 컨텍스트 분리 · 비밀키 외부화

도구 선택 이유 · 장 단 점

도 구	왜 사 용	장 점	단 점
Java 8 · Servlet/JSP	제약(고정)·가벼운 웹	의존성 최소·안정	보일러플레이트·최신문법 X
Tomcat · WAR	서블릿 표준·핫배포	가볍고 익숙	형제앱과 포트/컨텍스트 충돌
MariaDB	무료·한국어·집계	SQL 친숙·트랜잭션	한글 REGEXP 불안정
HikariCP	빠른 커넥션 풀	표준·누수 감지	DB 미기동 시 404
네이버 뉴스 API	합법 수집·키 보호	안정·일 25,000회	본문 전문 X (요약만)
KIS OpenAPI	실시간 시세	정확·실시간	토큰/초당 한도 뽕뽕
Groq (LLM)	무료·빠름·OpenAI 호환	1건 2초·한국어 OK	Cloudflare UA 차단·RPM

그 외: Gson(JSON) · Maven(빌드) · DART(재무) · Git/GitHub(형상) · start.ps1(원클릭 기동)

핵심 기법 개념 · 이유

● 유사 그룹화 (Jaccard)

제목 단어 겹침으로 같은 이슈 묶기 → 분석 대상 압축

● producer / consumer

수집=적재, 분석=큐 소비. DB의 analyzed_yn 이 곧 큐

● 캐시 + 풀백

시세 12초 캐시, 실패 시 마지막 정상값(0 깜빡임 방지)

● 토큰 영속화

토큰을 파일로 저장 → 재기동마다 재발급 안 함

● 대표 1건 + 전파

그룹당 1건만 LLM → 결과를 전체 전파 (비용 절감)

● 배치 LLM 호출

N개 그룹을 1호출로 묶어 RPD/RPM 절약

● 이중검사 락

토큰을 한 스레드만 발급 → 동시발급(EGW00133) 방지

● 문맥 키워드 매칭

금/은은 시세 문맥일 때만 인정 → 거짓 양성 제거

초기 구현 방식

골격 (skeleton)에서 출발

- 핵심 알고리즘(유사도 그룹화)은 완성, 일부는 TODO
- 수집과 분석이 한 실행에 결합 — CollectJob이 수집 직후 동기 분석까지
- LLM = Gemini, 분석은 수동 버튼으로 트리거
- API 키 없을 때는 mock 분석(generateMockAnalysis)으로 대체
- 종목 매핑은 4종목뿐 · market 컬럼은 'KOSPI/KOSDAQ' 자리표시자

그래서 생긴 한계

- 수집이 LLM 속도·무료 한도에 묶여 느려짐 (최대 5분 대기)
- 데이터 품질 이슈 — 쓰레기 '지수' 섹터, 자리표시자 market, 4종목 매핑
- KIS 시세가 갱신마다 0 ↔ 정상으로 깜빡임
- 무료 LLM 한도 초과로 백로그가 안 빠짐
- 섹터 자동매칭의 대량 거짓 양성(금·은 등)

사용하다 그만둔 것 · 이유

Gemini 무료

버린 이유: RPD 20회/일 → 백로그 못 빠짐

→ 보조 옵션으로 강등

Ollama 로컬 (CPU)

버린 이유: 품질 모델 1건 72초 → 너무 느림

→ GPU 머신용 옵션 유지

qwen2.5 / exaone 2.4b

버린 이유: 중국어 드리프트 / 스키마 실패

→ EXAONE 7.8B 채택

동기 결합 (수집·분석)

버린 이유: 수집이 LLM에 묶여 지연·실패

→ producer/consumer 분리

단일글자 섹터 매칭

버린 이유: 은행·현금·골드만삭스 오매칭

→ 문맥매칭 · LLM 판단

목업 분석 / OpenAI

버린 이유: 데이터 오염 / 유료 부담

→ Groq 실연결

데이터 품질

문제

대시보드 출력이 비거나 엉뚱함:
쓰레기 '지수' 섹터, market='KOSPI/KOSDAQ' 자리표시자,
news_stock_map이 단 4종목.

원인

- 목업 분석이 4종목만 하드코딩
- PopulateStocks가 HTTP 302로 0행
- 섹터-종목 마스터 매핑 공백

해결

- PopulateStocks를 KIND HTTPS로 재작성 → KOSPI 834 / KOSDAQ 1773 등재
- StockResolver 신설 – 이름·코드 매칭(2,700+ 종목)으로 매핑 2,265건으로 확대
- map_sector_stocks.sql 로 모든 업종/테마에 종목 연결
- 쓰레기 섹터 화이트리스트 가드(지수·거시경제 제외)

결과 4종목 → 2,265종목 매핑, 섹터 패널 정상화

KIS 시세 깜빡임

문제

관련 종목의 거래량·거래대금·시가총액이 갱신 때마다 0
↔ 정상값을 반복.

원인

- KIS rate limit(EGW00201) + 토큰 동시발급(EGW00133)
- 호출 실패 시 네이버 폴백이 vol/시총을 0으로 하드코딩

해결

- 종목별 시세 캐시(12초) + 실패 시 마지막 정상값 반환
- 글로벌 throttle + 토큰 발급 이중검사 락(동시발급 방지)
- 토큰을 디스크에 영속화 → 재기동마다 재발급 안 함
- 프론트는 0/빈값이면 갱신 스킵(직전 값 유지)

결과 깜빡임 제거 · EGW 에러 대폭 감소

수집/분석 결합 → 분리

문제

수집이 분석에 묶여 LLM이 느리면 수집까지 지연·실패.
백로그가 쌓여도 안 빠짐.

원인

- CollectJob이 수집 후 동기로 분석 호출(최대 5분 대기)
- 분석 처리량이 수집 유입량을 못 따라감

해결


- producer/consumer 분리 – CollectJob(적재만) + AnalyzeJob(분석)
- DB의 analyzed_yn='N' 이 곧 작업 큐 역할
- 노출도 컷(duplicate_count) + 최근 2일 + 배치 호출로 처리량 ↑
- 수집은 자동, 분석은 독립 실행

결과 수집이 LLM에 안 막힘 · 중요 뉴스 우선 처리

LLM 분석 엔진의 여정

● Gemini 무료	RPD 20회/일 — 백로그를 못 빠뜨림
● Ollama 로컬	무료·무제한이나 GPU 없어 CPU만
● L qwen2.5:7b	한국어인데 중국어로 드리프트 x
● L exaone 2.4b	빠르나 스키마 못 따라감(빈 출력) x
● L exaone 7.8b	품질OK, 그러나 1건 72초(200건≈4h)
● Groq 클라우드	무료·빠름 · 1건 2.4초 · 한국어 양호 ✓

1건 분석 처리 시간 (초, 낮을수록 좋음)



≈ 30배 빠름 — 함정: Groq는 Cloudflare 뒤 → Java 기본 UA 차단(403). User-Agent 헤더로 해결.

섹터 거짓 양성 (금·은 등) 정리

문제

섹터 매핑 1.2위가 '은' 9,446 / '금' 3,822 으로 비정상 폭증.


원인

단일·짧은 글자를 부분일치로 매칭 →
은행·은퇴·금융·현금·골드만삭스·실버타운까지 다 잡힘.

해결

금·은은 본문 추출에서 제외하고 LLM 의미판단으로만 인정.
조선·사료·통신·기계는 문맥 표현이 있을 때만 매칭.
related_sectors 재생성.

정리 전 → 후 (섹터 매핑 건수)



현재 구현 방식



수집

자동 10분 스케줄

증시·경제·정책·과학 + 상장 종목 키워드.
QuotaGuard 일일 한도(25k) 가드.



분석·요약

‘ 분석·요약 실행 ’ 버튼

적재된 뉴스를 Groq 배치 분석 →
호재/악재·영향도·섹터·종목 매핑.



표출

대시보드 (최근 3일)

주요 이슈 · 연관 섹터(버즈량) ·
종목 신호 · 실시간 시세 바.



인프라

원클릭 기동·영속화

start.ps1이 MariaDB·Ollama 자동기동.
토큰 디스크 캐시 · GitHub 연동.

향후 개선 제안

● 데이터 정확도

- 섹터 오매칭 잔여(조선·통신) 추가 정리
- related_sectors 일관성 자동 보정
- 가중 버즈량 vs 고유 건수 지표 선택 옵션

● 분석 품질·성능

- 임베딩 기반 유사도(TF-IDF/벡터)로 그룹화 고도화
- 프롬프트·few-shot 정교화로 판정 일관성 ↑
- 분석 결과 캐싱·증분 처리

● 운영·보안

- 형제 /newssignal 분리 → 설정 리셋 차단
- API 키 외부화(.env/Secret) · CI 빌드
- 스케줄/에러 모니터링·알림

● 기능 확장

- 종목별 호재·악재 타임라인
- 급변 신호 실시간 알림(관심종목)
- 신호 기반 간이 백테스트

SUMMARY

골격에서 출발해, 5번의 문제를 거쳐 안정적인 무료 파이프라인으로

● 데이터 품질

4종목 → 2,265종목, 섹터 정밀화

● 시세·구조

캐시·토큰 영속화 · 수집/분석 분리

● LLM 엔진

Gemini → Ollama → Groq (≈30배 가속)

"수집은 자동, 분석은 버튼, 신호는 명확하게."